

Detector de fraude con tarjeta de crédito: pipeline MLOps reproducible con DVC, MLflow y despliegue en Cloudflare


Eduardo García López y Fernando Ramos Ríos

• ITESO — Integración de Servicios de Aprendizaje Automático (ISAA) — Primavera 2026

INTRODUCCIÓN

El fraude con tarjeta de crédito ocurre en menos del 0.2% de las transacciones (OpenML 1597, ULB, ~284 807 transacciones, 29 atributos numéricos): un problema severamente desbalanceado que exige métricas centradas en la clase positiva, en particular PR-AUC.

- El pivote de AWS a Cloudflare fue forzado por la suspensión de una cuenta académica, pero refuerza el mensaje MLOps: entrenar en Python, exportar a ONNX, servir como contenedor en el edge.




MATERIALES Y MÉTODOS

Un pipeline MLOps disciplinado (DVC + MLflow + registro por alias + verificación de paridad) lleva un modelo desde notebook hasta endpoint público sin perder reproducibilidad ni precisión.

- ONNX desacopla el entrenamiento de la plataforma de inferencia; los Containers de Cloudflare son alternativa creíble a SageMaker para prototipos académicos.
- Repo: github.com/LaloLalo1999/mlops · Endpoint: fraud-detector.eduardo-lalo1999.workers.dev

Contenido del bucket R2 «luci-mlops-fraud»
50 objetos · 152.1 MB total




RESULTADOS

Pipeline en cinco etapas, orquestado por DVC sobre Python 3.11:



- 1. Ingesta + preprocesamiento (OpenML 1597, partición estratificada 80/20).
- 2. Entrenamiento de 7 corridas (LogReg baseline, LightGBM, XGBoost) variando hiperparámetros y técnicas de balanceo.
- 3. Registro en MLflow — métricas, artefactos, y alias `fraud-detector@staging` sobre el mejor modelo.
- 4. Sincronización a Cloudflare R2 (bucket `luci-mlops-fraud`, 75 objetos, ~167 MB) vía la API de gestión REST.
- 5. Despliegue: ONNX (opset 15, `zipmap=False`) en contenedor Docker (FastAPI + `onnxruntime`) detrás de Worker + Durable Object.

Pipeline MLOps — entrenamiento reproducible → inferencia en el edge



Mejor modelo — `xgb-d6-lr05-n500`: PR-AUC 0.8819, ROC-AUC 0.9789.
Umbral 0.9274 ⇒ F1 0.874, precisión 0.941, recall 0.816.

Inferencia en vivo: el endpoint en Cloudflare coincide con sklearn en 100/100 filas dentro de 1×10^{-4} , latencia mediana 253 ms (p95 613 ms).



AGRADECIMIE

A ITESO y al profesor de Integración / despliegue en Cloudflare en lugar de A alimentaron este proyecto final.